

1 Statistiques à deux variables

I. Position du problème, vocabulaire

Le problème qui se pose dans les séries statistiques à deux variables est principalement celui du lien qui existe ou non entre chacune des variables. Par soucis de clarté, ce cours est élaboré à partir de l'exemple suivant :

Exemple 1

Le tableau suivant donne l'évolution du nombre d'adhérents d'un club de rugby de 2001 à 2006.

Année	2001	2002	2003	2004	2005	2006
Rang x_i	1	2	3	4	5	6
Nombre d'adhérents y_i	70	90	115	140	170	220

Le but est d'étudier cette série statistique à deux variables (le rang et le nombre d'adhérents) afin de prévoir l'évolution du nombre d'adhérents pour les années suivantes.

I. 1. Nuage de points

La première étape consiste à réaliser un graphique qui traduise les deux séries statistiques ci-dessus.

Déf. 1

Soit X et Y deux variables statistiques numériques observées sur n individus.

Dans un repère orthogonal $(O; \vec{i}; \vec{j})$, l'ensemble des n points de coordonnées (x_i, y_i) forme le nuage de points associé à cette série statistique.

Dans notre exemple, si on place le rang en abscisses, et le nombre d'adhérents en ordonnées, on peut représenter par un point chaque valeur. On obtient ainsi une succession de points, dont les coordonnées sont $(1; 70)$, $(2; 90)$, ... $(6; 220)$, forment un nuage de points.

Exemple 2


Dans le plan muni d'un repère orthogonal d'unités graphiques : 1, 5 cm pour une année sur l'axe des abscisses et 1 cm pour 20 adhérents sur l'axe des ordonnées, représenter le nuage de points associé à la série $(x_i; y_i)$.

T.I.

- Touche **STAT**
- Menu **EDIT**
- Entrer les valeurs x_i dans L_1
- Entrer les valeurs y_i dans L_2
- Régler les valeurs du repère avec la touche **WINDOWS**
- Appuyer sur la touche **TRACE**

Casio

- Menu **STAT**
- Entrer les valeurs x_i dans $List1$
- Entrer les valeurs y_i dans $List2$
- Choisir **GRPH**
- Régler les paramètres avec **SET**
- Choisir **GPH1**



I. 2. Le problème de l'ajustement

Remarque. Le nuage de points associé à une série statistique à deux variables donne donc immédiatement des informations de nature qualitatives. Pour en tirer des informations plus quantitatives, il nous faut poser le problème de l'ajustement. Le tracé met en évidence la possibilité de "reconnaître" graphiquement la possibilité d'une relation fonctionnelle entre les deux grandeurs observées (ici rang et nombre d'adhérent). Le problème de l'établissement d'une relation fonctionnelle entre les deux séries est le problème de l'ajustement.

I. 3. Point moyen

Définition 2

Soit une série statistique à deux variables, X et Y , dont les valeurs sont des couples $(x_i; y_i)$. On appelle point moyen de la série le point G de coordonnées

- $x_G = \frac{x_1 + x_2 + \dots + x_n}{n} = \bar{x}$.
- $y_G = \frac{y_1 + y_2 + \dots + y_n}{n} = \bar{y}$.

Exemple 3

Déterminer les coordonnées des points moyens suivants :

- G_1 des années allant de 2001 à 2003,
- G_2 des années allant de 2004 à 2006,
- G , point moyen du nuage de points tout entier.

$$\text{Calcul des coordonnées de } G_1 : \begin{cases} x_{G_1} = \frac{1+2+3}{3} = 2 \\ y_{G_1} = \frac{70+90+115}{3} = 91,7 \end{cases} \quad \text{donc, } \boxed{G_1(2 ; 91,7)}.$$

$$\text{Calcul des coordonnées de } G_2 : \begin{cases} x_{G_2} = \frac{4+5+6}{3} = 5 \\ y_{G_2} = \frac{140+170+220}{3} = 176,7 \end{cases} \quad \text{donc, } \boxed{G_2(5 ; 176,7)}.$$

$$\text{Calcul des coordonnées de } G : \begin{cases} x_G = \frac{1+2+3+4+5+6}{6} = 3,5 \\ y_G = \frac{70+90+115+140+170+220}{6} = 134,2 \end{cases} \quad \text{donc, } \boxed{G(3,5 ; 134,2)}.$$

II. Ajustements

II. 1. Ajustement à la règle

On se propose, à partir des résultats obtenus, de faire des prévisions pour les années à venir.

Un moyen d'y parvenir est de tracer au juger une droite $\mathcal{D}$ passant le plus près possible des points du nuage et d'en trouver l'équation du type $y = ax + b$.

II. 2. Méthode de Mayer

Cet ajustement consiste à déterminer la droite passant par deux points moyens du nuage de point.

Exemple 4

Déterminer l'équation de la droite $\mathcal{D}_1$ qui passe par les points moyens G_1 et G_2 et la tracer sur le graphique précédent.

La droite $\mathcal{D}_1$ n'est pas parallèle à l'axe des ordonnées, elle a donc pour équation $y = ax + b$ avec :


$$a = \frac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}} = \frac{176,7 - 91,7}{5 - 2} = 28,3.$$

De plus, elle passe par le point $G_1(2 ; 91,7)$ d'où :

$$y_{G_1} = ax_{G_1} + b \Rightarrow 91,7 = 28,3 \times 2 + b \Rightarrow b = 35,1.$$

Conclusion : $\boxed{\mathcal{D}_1 : y = 28,3x + 35,1}$.

Pour tracer $\mathcal{D}_1$, il suffit de placer G_1 et G_2 puis de tracer la droite qui les relie.



II. 3. Méthode des moindres carrés

Il s'agit d'obtenir une droite qui minimise la distance entre la droite et les points situés de part et d'autre d'elle-même.

Pour réaliser ceci, on cherche à minimiser la somme des distances des points à la droite au carré, ce qui permet de ne pas tenir compte du signe des écarts.

On considère une série statistique à deux variables représentée par un nuage justifiant un ajustement affine.

Définition 3


Dans le plan muni d'un repère orthonormal, on considère un nuage de n points (M_i) de coordonnées $(x_i; y_i)$ et n points Q_i de coordonnées $(x_i; ax_i + b)$ tous alignés sur la droite d'équation $y = ax + b$.

La droite $\mathcal{D}$ d'équation $y = ax + b$ est appelée droite de régression de y en x de la série statistique si et seulement si la quantité suivante est minimale :

$$\sum_{i=1}^n (M_i Q_i)^2 = \sum_{i=1}^n [y_i - (ax_i + b)]^2$$

Exemple 5

Représentation graphique d'une droite de régression de y en x pour un nuage de 6 points.



Remarque. Il serait tout aussi judicieux de s'intéresser à la droite $\mathcal{D}'$ qui minimise la quantité

$$\sum_{i=1}^n [x_i - (ay_i + b)]^2.$$

Cette droite est appelée droite de régression de x en y .

Déf. 4

On appelle covariance de la série statistique double de variables x et y le nombre réel

$$\text{cov}(x, y) = \sigma_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Propriété 1

Pour les calculs, on pourra aussi utiliser la formule de König :

$$\sigma_{xy} = \frac{1}{n} \left(\sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y}.$$

Remarque. On a : $\text{cov}(x, x) = \sigma_{x^2} = V(x) = [\sigma(x)]^2$.

Propriété 2

La droite de régression D de y en x a pour équation $y = ax + b$ où

$$\begin{cases} a = \frac{\sigma_{xy}}{\sigma_x^2} \\ b \text{ vérifie } \bar{y} = a\bar{x} + b \end{cases}$$

Remarque. Les réels a et b sont donnés par la calculatrice.

T.I.

- Touche STAT
- Menu CALC
- Item LinReg
- LinReg L_1, L_2

Casio

- Menu STAT
- Item CALC
- Régler les paramètres avec set
- Item REG
- Choisir X

Propriété 3

Le point moyen G du nuage appartient toujours à la droite de régression de y en x .

Exemple 6

Déterminer une équation de la droite d'ajustement $\mathcal{D}_2$ de y en x obtenue par la méthode des moindres carrés pour la série statistique de l'exemple 1.

La calculatrice donne $\mathcal{D}_2 : y = ax + b$ avec $a = 29$ et $b = 32,7$.


Conclusion : $\mathcal{D}_2 : y = 29x + 32,7$

Pour tracer la droite $\mathcal{D}_2$, il faut choisir deux points (au moins) sur cette droite.

Par exemple :

x	0	8
y	32,7	264,7

 , les placer dans le repère puis tracer la droite.



II. 4. Ajustement exponentiel

On remarque qu'un ajustement affine ne semble pas très approprié pour ce nuage de points à partir de 2006, on se propose de déterminer un ajustement plus juste.

Exemple 7

On pose $z = \log y$. Recopier et compléter le tableau suivant en arrondissant les valeurs de z_i au millièème.

x_i	1	2	3	4	5	6
z_i	1,845	1,954	2,060	2,146	2,230	2,342

On peut déterminer les éléments de ce tableau grâce à la calculatrice :

T.I.

- Touche STAT
- Menu EDIT
- Se placer dans L_3
- Entrer la formule " $= \log L_2$ "

Casio

- Touche STAT
- Menu EDIT
- Se placer sur List3
- Entrer la formule " $\log List2$ "

Exemple 8

Déterminer une équation de la droite d'ajustement $\mathcal{D}_3$ de z en x obtenue par la méthode des moindres carrés.

La manipulation à la calculatrice est la même que précédemment, en oubliant pas de changer les paramètres.

La calculatrice donne $\mathcal{D}_3 : z = ax + b$ avec $a = 0,224$ et $b = 4,045$.

Conclusion : $\mathcal{D}_3 : z = 0,0971x + 1,75627$.

Exemple 9


Dans ce cas, en déduire la relation qui lie y à x puis tracer la courbe représentative de la fonction $y = f(x)$.

$$\text{On a } \begin{cases} z = 0,0971x + 1,75627 \\ z = \log y \end{cases} \quad \text{donc : } \log y = 0,0971x + 1,75627$$

$$\begin{aligned} \text{On compose par la fonction exponentielle : } 10^{\ln y} &= 10^{0,0971x + 1,75627} \\ &= (10^{0,0971})^x \times 10^{1,75627} \\ &= (1,251)^x \times 57,052 \end{aligned}$$

Conclusion : $y = 57,052 \times 1,251^x$.

Pour tracer la courbe, il suffit de placer des points, par exemple grâce au tableau de valeurs de la calculatrice.



III. Comparaisons des ajustements

Grâce aux trois derniers ajustements, on peut évaluer ce qui se passera plus tard, comparons les :

Exemple 10

En supposant que les ajustements restent valables pour les années suivantes, donner une estimation du nombre d'adhérents en 2007 suivant les trois méthodes.

Dans tous les cas, il faut calculer y lorsque x correspond à l'année 2007, c'est à dire au rang 7.

- Méthode de Mayer : $y = 28,3 \times 7 + 35,1 = 233,2$ soit environ 233 adhérents.
- Ajustement affine : $y = 29 \times 7 + 32,7 = 235,7$ soit environ 236 adhérents.
- Ajustement exponentiel : $y = 57,112 \times 1,024^7 = 273,9$ soit environ 274 adhérents.

Exemple 11

En 2007, il y a eu 280 adhérents. Lequel des trois ajustements semble le plus pertinent ?

Le troisième ajustement semble le plus pertinent puisqu'il se rapproche le plus de la réalité.

III. 1. Coefficient de corrélation linéaire

Déf. 5

Le coefficient de corrélation linéaire d'une série statistique de variables x et y est le nombre r défini par :

$$r = \frac{\sigma_{xy}}{\sigma(x) \times \sigma(y)}.$$

Ce coefficient sert à mesurer la qualité d'un ajustement affine.

Interprétation graphique :

Plus le coefficient de régression linéaire est proche de 1 en valeur absolue, meilleur est l'ajustement linéaire. Lorsque $r = \pm 1$, la droite de régression passe par tous les points du nuage, qui sont donc alignés.

Exemple 12

Déterminer le coefficient de corrélation linéaire dans le cas de l'ajustement affine (entre x et y), puis exponentiel (entre x et z). Quel est l'ajustement le plus juste ?

Grâce à la calculatrice, on trouve successivement $r_2 = 0,987$ puis $r_3 = 0,999$.

Ce qui est conforme à ce que nous avons déduit précédemment, à savoir que l'ajustement exponentiel est plus fiable pour ce cas.

Propriété 4

Le coefficient de corrélation linéaire r vérifie $-1 \leq r \leq 1$.

IV. Exercices

Exercice 1.

Corrigé page 13

Calculer les coordonnées du point moyen de la série suivante :

x_i	200	205	208	211	215
y_i	5200	5400	5600	5900	6400

Exercice 2.

Corrigé page 13

Déterminer x et y pour que le point moyen de la série soit de coordonnées $(7,5 ; 12,6)$.

x_i	8,2	7,4	x	6,1	9
y_i	15	12,1	16,3	y	12

Exercice 3.

Corrigé page 13

On considère la série statistique double ci-dessous.

x_i	1	3	4	6	7	8
y_i	11,1	13	14,5	16	16,9	19

1. Représenter le nuage de points $M_i(x_i, y_i)$ dans un repère orthonormé.
2. Calculer les coordonnées du point moyen et placer ce point dans le repère.
3. Donner une équation de la droite de régression de y en x obtenue par la méthode des moindres carrés et tracer cette droite dans le repère. (a et b seront arrondis à 0,01 près)

Exercice 4.

Corrigé page 13

Le tableau suivant donne la moyenne y des maxima de tension artérielle en fonction de l'âge x .

âge x_i	36	42	48	54	60	66	70
tension y_i	12	13	13,6	14,3	15,4	15,8	16

1. Donner une équation de la droite de régression de y en x obtenue par la méthode des moindres carrés. (a et b seront arrondis à 0,01 près)
2. Quelle serait la tension théorique d'une personne de 75 ans en utilisant le modèle de la droite des moindres carrés? (arrondir le résultat à 0,1 près)

Exercice 5.

Corrigé page 14

Le tableau suivant indique la teneur en CO₂ depuis 1850.

Année	1850	1900	1950	1990
Rang de l'année : x_i	0	50	100	140
Teneur en CO ₂ : y_i	275	290	315	360
$z_i = \log(y_i - 250)$				

1. Compléter dans le tableau la ligne indiquant $z_i = \log(y_i - 250)$.
2. Donner une équation de la droite de régression de z en x obtenue par la méthode des moindres carrés. (a et b seront arrondis à 0,01 près)
3. Selon ce modèle, quel serait le taux de CO₂ en 2050 ? (donner le résultat à une unité près)


Exercice 6.

Corrigé page 15


Le tableau suivant donne le nombre d'abonnés à un jeu en ligne.

Année	2014	2015	2016	2017	2018
Rang de l'année x_i	1	2	3	4	5
Nombre d'abonnés y_i (en milliers)	40	80	130	260	420
$z_i = \log y_i$					

1. Le nuage de points $A_i(x_i, y_i)$ est représenté ci-dessous. Un ajustement affine vous semble-t-il adapté ?



2. Compléter dans le tableau la ligne indiquant $z_i = \log y_i$. (arrondir à 0,01 près)
3. Représenter le nuage de points $B_i(x_i, z_i)$ dans le repère ci-dessous :



4. Donner une équation de la droite de régression de z en x obtenue par la méthode des moindres carrés et tracer cette droite dans le repère. (a et b seront arrondis à 0,001 près)
5. En déduire l'expression de y en fonction de x en suivant ce modèle. (on écrira y sous la forme $A \times 10^{Bx}$ en arrondissant A à 0,001 près)
6. Selon ce modèle, quel serait le nombre d'abonnés en 2022 ? (donner le résultat au millier près)

V. Corrigés

Corrigé de l'exercice 1.

[Retour à l'énoncé](#)

$$\bar{x} = 207,8 \quad ; \quad \bar{y} = 700$$

Corrigé de l'exercice 2.

[Retour à l'énoncé](#)


$$\text{On doit avoir } \begin{cases} \frac{8,2 + 7,4 + x + 6,1 + 9}{15 + 12,1 + 16,3 + y + 12} = 7,5 \\ \frac{5}{5} = 12,6 \end{cases}$$

$$\Leftrightarrow \begin{cases} \frac{30,7 + x}{55,4 + y} = 7,5 \\ \frac{5}{5} = 12,6 \end{cases} \Leftrightarrow \begin{cases} 30,7 + x = 37,5 \\ 55,4 + y = 63 \end{cases} \Leftrightarrow \begin{cases} x = 6,8 \\ y = 7,6 \end{cases}$$

Corrigé de l'exercice 3.

[Retour à l'énoncé](#)

1.



2. $\bar{x} = 4,83 \quad ; \quad \bar{y} = 15,8$

3. $y = 1,06x + 9,95$

Corrigé de l'exercice 4.

[Retour à l'énoncé](#)

1. $y = 0,12x + 7,84$

2. Si $x = 75$, $y \approx 16,8$

Corrigé de l'exercice 5.[Retour à l'énoncé](#)

1.

Année	1850	1900	1950	1990
Rang de l'année : x_i	0	50	100	140
Teneur en CO ₂ : y_i	275	290	315	360
$z_i = \log(y_i - 250)$	1,398	1,602	1,813	2,041

2. $z = 0,004537x + 1,3846$ 3. 2050 correspond à $x = 200$.

On a alors $z \approx 0,004537 \times 200 + 1,3846 \Leftrightarrow \log(y - 250) \approx 2,292 \Leftrightarrow y - 250 \approx 10^{2,292}$
 $\Leftrightarrow y \approx 250 + 10^{2,292} \approx 446$


Corrigé de l'exercice 6.[Retour à l'énoncé](#)

1. Non.

2.

Année	2014	2015	2016	2017	2018
Rang de l'année x_i	1	2	3	4	5
Nombre d'abonnés y_i (en milliers)	40	80	130	260	420
$z_i = \log y_i$	4,602	4,903	5,114	5,415	5,623

3.

4. $z = 0,255x + 4,365$ 5. $\log y = 0,255x + 4,365 \Leftrightarrow y = 10^{0,255x+4,365} = 10^{0,255x} \times 10^{4,365} \approx 23,173 \times 10^{0,255x}$ 6. 2022 correspond à $x = 9$.

On a alors $y \approx 23,173 \times 10^{0,255 \times 9} \approx 4570$ milliers d'abonnés.